

Universidade de São Paulo

Escola de Engenharia de São Carlos

Departamento de Engenharia Mecânica



Projeto de Iniciação Científica

Detecção e Controle de Ervas Daninhas

Orientador: Mário Luiz Tronco

Aluno: Luciano Gonçalves Lopes Filho

São Carlos, Setembro de 2024

Prefácio

Este documento refere-se à proposta de projeto de iniciação científica do discente Luciano Gonçalves Lopes Filho, o qual é aluno regularmente matriculado no curso de Engenharia de Computação da Escola de Engenharia de São Carlos (EESC) da Universidade de São Paulo (USP). Prevê-se neste projeto que o docente e pesquisador, Prof. Dr. Mário Luiz Tronco, atue como orientador do discente referido e na coordenação das atividades de pesquisa.

Sumário

1	Introdução	5
2	Objetivos	6
3	Revisão Bibliográfica	7
3.1	O Impacto Econômico das Ervas Daninhas na Produção Nacional	7
3.2	Controle de Ervas Daninhas em Culturas Nacionais	8
3.2.1	Manejo Preventivo	8
3.2.2	Controle de Culturas	9
3.2.3	Controle Mecânico	9
3.2.4	Controle Físico	10
3.2.5	Controle Biológico	10
3.2.6	Controle Químico	11
3.3	O Uso de Visão Computacional na Identificação de Ervas Daninhas	11
3.4	Técnicas de Inteligência Artificial aplicadas à detecção de ervas Daninhas .	16
3.5	Projetos Anteriores	19
4	Metodologia e Cronograma	20
4.1	Cronograma	23
5	Materiais e Infraestrutura	24
6	Resultados	25

Lista de Tabelas

1	Custo por hectare (R\$) em diferentes situações de resistência ao longo dos anos[1]	7
2	Registro de ocorrência do primeiro relato de resistência da espécie ao glifosato[12]	8
3	Vantagens e desvantagens do controle químico de plantas daninhas.	11
4	Sensibilidade e Especificidade na horta de Espinafre 1 [10]	15
5	Sensibilidade e Especificidade na horta de Espinafre 2 [10]	16
6	Sensibilidade e Especificidade na horta de acelga [10]	16
7	Comparação entre modelos de detecção de objetos[5]	17
8	Detecção de ervas daninhas sob diferentes condições de luz e clima [5]	18
9	Avaliação de Sistemas de Controle de Ervas Daninhas [7]	19

Lista de Figuras

1	Diagrama de Blocos do Sistema de Visão, Adaptado de [10]	12
2	Imagem de Entrada [10]	12
3	Imagem com componentes subtraídos [10]	13
4	Imagem com filtro mediano [10]	13
5	Histograma [10]	13
6	Imagem Segmentada [10]	14
7	Imagem com regiões preenchidas [10]	14
8	Plantas Detectadas [10]	15
9	Divisão das Etapas do Projeto	20
10	Cronograma	23

1 Introdução

No cenário atual da economia brasileira, o agronegócio desempenha um papel fundamental, representando uma contribuição significativa para o Produto Interno Bruto (PIB) do país. Em 2024, estima-se que esse setor será responsável por R\$ 2,45 trilhões, correspondendo a 21,5% do PIB [2]. Essa importância econômica é acompanhada por uma crescente competitividade, impulsionada pela demanda cada vez maior de empresas e consumidores por uma produção de alimentos que seja sustentável e socialmente responsável. Tal exigência coloca uma pressão adicional sobre os produtores rurais, que precisam aumentar a produtividade sem expandir a área de cultivo. Para alcançar esses objetivos, diversas técnicas, como a correção de solo, irrigação, adubação e, em especial, o controle de ervas daninhas, são amplamente empregadas.

No entanto, o controle de ervas daninhas tem se tornado um desafio cada vez maior para os produtores. Os altos custos dos agrotóxicos, combinados com a proibição frequente de fórmulas específicas devido aos riscos que apresentam à saúde humana e ao meio ambiente, geram prejuízos significativos para os agricultores e cooperativas que dependem desses produtos. Além disso, um problema emergente é o surgimento de ervas daninhas resistentes aos pesticidas [11], que podem evoluir e se transformar em pragas incontroláveis, agravando ainda mais a situação.

Diante desse cenário desafiador, esta proposta de iniciação científica busca desenvolver um algoritmo baseado em redes neurais convolucionais (CNNs) para o reconhecimento de plantas invasoras. Além disso, será projetado um mecanismo de capina mecânica, que será integrado a um dos robôs do laboratório do professor orientador, com o objetivo de realizar o controle eficiente de plantas indesejadas em lavouras.

A necessidade de aumentar a produção nacional pode ser vista como uma oportunidade de desenvolver o parque industrial nacional, inicialmente apoiando a indústria trilionária do agronegócio, mas posteriormente a tecnologia desenvolvida pode tornar o Brasil competitivo em outros setores, como a indústria química, de semicondutores e de máquinas pesadas.

2 Objetivos

Considerando o panorama geral do projeto, esse trabalho de iniciação científica tem como objetivos:

- Desenvolver algoritmos de detecção de ervas daninhas utilizando tecnologias como YOLO e MobileNet.
- Realizar o desenvolvimento, manufatura e controle de um sistema mecânico para a remoção de plantas
- Implementar o algoritmo como parte de um sistema embarcado em um robô agrícola, dedicado a fazer a remoção de ervas daninhas por meio de da capina mecânica desenvolvida.
- Validar a solução por meio de testes em campo e análise dos resultados.

3 Revisão Bibliográfica

Visando identificar o estado geral do desenvolvimento das áreas relacionadas com esse projeto, a revisão bibliográfica foi organizada em assuntos específicos, de acordo com as subseções abaixo.

3.1 O Impacto Econômico das Ervas Daninhas na Produção Nacional

As ervas daninhas representam um dos principais desafios para a agricultura brasileira, competindo diretamente com as culturas por recursos como água, nutrientes e luz solar. Em algumas culturas, como a soja, milho e cana-de-açúcar, a presença dessas plantas invasoras pode causar reduções significativas na produtividade, além de aumentar o custo de produção dado a necessidade do emprego de técnicas de controle dessas plantas.

No artigo "Impacto econômico da resistência de plantas daninhas a herbicidas no Brasil"[1], divulgado na 132ª Circular Técnica da Embrapa Soja, embora o uso de herbicidas seja amplamente utilizado nas monoculturas no Brasil, e sendo o mais eficaz método de controle de ervas daninhas, o surgimento de plantas resistentes a esses produtos químicos vem se tornando um problema cada vez maior para a agricultura.

O processo de seleção de biotipos resistentes ocorre por pressão evolutiva, no qual o uso intensivo de herbicidas seleciona indivíduos resistentes ao princípio ativo do defensivo agrícola, resultado de mutações genéticas, os indivíduos resistentes restantes se reproduzem, sendo muito mais difícil controlar o seu crescimento populacional.

Nas lavouras de grãos brasileiras, em especial a soja, o impacto das ervas daninhas resistentes teve duas fases. A primeira ocorreu de meados dos anos 90 até meados dos anos 2000 quando herbicidas baseados na inibição da enzima ALS eram utilizados em larga escala para o combate de ervas dicotiledôneas, e herbicidas inibidores da ACCase foram utilizados para o combate de ervas monocotiledôneas, selecionando populações resistentes aos dois principais tipos de defensivos.

O resultado foi a elevação significativa do custo de controle das ervas daninhas, sendo que em algumas regiões afetadas o custo era considerado insustentável pelos produtores, como mostra a tabela abaixo, com valores ajustados em julho de 2017.

Tabela 1: Custo por hectare (R\$) em diferentes situações de resistência ao longo dos anos[1]

SITUAÇÃO (período/anos)	MÍNIMO (R\$ ha ⁻¹)	MÁXIMO (R\$ ha ⁻¹)	MÉDIA (R\$ ha ⁻¹)
SEM RESISTÊNCIA (1993 – 2001)	46,53	78,60	62,57
COM RESISTÊNCIA (1996 – 2005)	228,59	343,37	285,98
SOJA RR (2005 – 2007)	82,89	101,16	92,03

Entretanto, a situação foi revertida com a introdução da soja transgênica (Soja RR) no Brasil, resistente ao glifosato, o que permitiu o uso desse herbicida nas lavouras do

país. O uso extensivo do glifosato criou o que se considera a segunda fase de resistência plantas daninhas no Brasil, agora algumas espécies de plantas resistentes tanto ao glifosato quanto a inibidores ACCase ou ALS. O que levou a Embrapa a conduzir estudos de monitoramento do surgimento e proliferação de ervas daninhas resistentes.

Tabela 2: Registro de ocorrência do primeiro relato de resistência da espécie ao glifosato[12]

Ano	Nome comum	Nome científico	Estado
2003	azevém	<i>Lolium perene</i> spp <i>multiflorum</i>	RS
2005	buva	<i>Conyza bonariensis</i>	RS, SP
2005	buva	<i>Conyza canadensis</i>	SP
2008	capim-amargoso	<i>Digitaria insularis</i>	PR
2010	buva	<i>Conyza sumatrensis</i>	PR
2014	capim-branco	<i>Chloris elata</i>	SP
2015	caruru-palmeri	<i>Amaranthus palmeri</i>	MT
2016	capim-pé-de-galinha	<i>Eleusine indica</i>	PR
2018	caruru	<i>Amaranthus hybridus</i>	RS
2019	leiteiro	<i>Euphorbia heterophylla</i>	PR
2020	capim-arroz	<i>Echinochloa cruz-galli</i> var <i>cruz-galli</i>	RS
2023	picão-preto	<i>Bidens subalternans</i>	PR

A lista de espécies resistentes aumenta a cada ano e existe o risco de que o mesmo cenário visto durante a primeira fase da resistência das plantas daninhas no Brasil. Enquanto novos tipos herbicidas e sementes geneticamente modificadas forem utilizados como resposta, esse ciclo continua, colocando em risco a segurança alimentar e economia nacional.

3.2 Controle de Ervas Daninhas em Culturas Nacionais

Segundo os autores Oliveira (OLIVEIRA, M. F. de) e Brighenti (BRIGHENTI, A. M.)[9], as ferramentas de controle de plantas daninhas são divididas em manejo preventivo, controle cultural, mecânico, físico, biológico e químico. Essa subseção será dedicada a falar um pouco de cada uma delas.

3.2.1 Manejo Preventivo

O manejo preventivo é uma estratégia essencial para o controle de plantas daninhas, com foco em evitar a entrada, estabelecimento e disseminação de espécies problemáticas em áreas ainda não infestadas (Silva et al., 2007b). Um bom programa de manejo envolve vigilância constante das áreas de cultivo, identificando as plantas na fase jovem e adulta e prevenindo sua entrada, uma vez que o controle posterior tende a ser mais oneroso. Entre as medidas preventivas, destacam-se: a limpeza de máquinas e implementos agrícolas, uso de sementes certificadas, quarentena de animais comprados e manutenção de áreas livres de plantas daninhas. A ausência dessas práticas tem contribuído para a disseminação

de espécies como buva (*Conyza* spp.) e capim-amargoso (*Digitaria insularis*), através de implementos inadequadamente limpos ou movimentação de animais entre áreas infestadas e não infestadas.

3.2.2 Controle de Culturas

O controle cultural é uma estratégia que visa usar boas praticas agrícolas para favorecer o desenvolvimento das plantas daninhas. Este método envolve praticas agrícolas para favorecer o desenvolvimento das culturas em detrimento das plantas daninhas. Este método envolve práticas como rotação de culturas, variação de espaçamento, consórcio de cultivos e uso de cobertura verde. O objetivo é suprimir o crescimento das plantas daninhas e reduzir o banco de sementes no solo, diminuindo a infestação nos anos seguintes (Silva et al., 2007b). A rotação de culturas é uma das práticas mais eficazes, diversificando o ambiente e dificultando a seleção de espécies mais problemáticas. Além disso, a integração lavoura-pecuária tem mostrado ser eficiente na supressão de plantas daninhas, por meio da variação no manejo. Já o consórcio de cultivos, como o sistema de milho + braquiária, protege o solo e reduz o acesso das plantas daninhas à luz. A cobertura do solo na entressafra visa substituir plantas de difícil controle por espécies de manejo mais fácil, e seu sucesso varia conforme as condições locais. Na região Centro-Oeste, o consórcio milho safrinha com braquiária tem sido uma prática eficiente, assim como o uso de plantas oleaginosas e outras culturas adaptadas às condições da região (Ceccon; Concenço, 2014).

3.2.3 Controle Mecânico

Os métodos de controle mecânico das plantas daninhas são divididos em arranquio, capina manual, roçada e cultivo mecanizado.

O arranquio manual é o método mais antigo e simples, ideal para áreas localizadas, como jardins ou pequenos canteiros. Já a capina manual, que utiliza ferramentas como enxadas e enxadões, é mais eficiente que o arranquio, sendo adotada em pequenas áreas devido ao maior rendimento operacional. Esses métodos têm ganhado importância em áreas urbanas devido à proibição do uso de agrotóxicos em áreas públicas.

A roçada manual ou mecânica é eficiente em culturas com espaçamentos maiores, como pomares e cafezais, especialmente em terrenos declivosos, onde também auxilia no controle da erosão. Em áreas como beiras de estradas e terrenos baldios, a roçada é amplamente utilizada para controle de plantas daninhas.

O cultivo mecanizado pode ser realizado com tração animal ou mecânica. A tração animal é uma opção mais barata e eficiente em áreas com espaçamentos reduzidos e terrenos declivosos, como em cafezais. Em áreas planas, no entanto, a tração mecânica se destaca pela rapidez e eficiência no controle de plantas anuais jovens, principalmente em

condições de solo seco.

Avanços recentes, como o desenvolvimento de implementos mecanizados e tecnologias inovadoras, como robótica e sistemas de detecção, têm ampliado a eficiência do controle mecânico, especialmente em sistemas de cultivo orgânico. Essas novas tecnologias oferecem maior precisão no manejo de plantas daninhas, reduzindo a necessidade de capina manual e promovendo um controle mais sustentável (Van der Weide et al., 2008)

3.2.4 Controle Físico

O controle físico de plantas daninhas envolve a utilização de métodos que não dependem de produtos químicos, mas sim de práticas que alteram o ambiente físico para dificultar o desenvolvimento dessas plantas. Entre os métodos mais utilizados estão o fogo e o uso de corrente elétrica e micro-ondas.

O uso do fogo como controle de plantas daninhas já foi amplamente empregado, porém, com o aumento das regulamentações ambientais e a disponibilidade de herbicidas, esse método perdeu popularidade. No entanto, ainda é utilizado em práticas agrícolas orgânicas, como na cana-de-açúcar e em citricultura, para controlar espécies que não são bem manejadas por herbicidas. O fogo atua desnaturando proteínas e danificando as membranas celulares das plantas, porém sua eficácia depende do estágio de desenvolvimento das plantas daninhas e sua suscetibilidade ao calor. Em sistemas orgânicos, o controle com lança-chamas pode substituir capinas manuais, embora seja uma prática de custo elevado.

O uso de micro-ondas e corrente elétrica para controle de plantas daninhas é um campo em desenvolvimento desde o final do século 19. As micro-ondas, por exemplo, atuam aquecendo os tecidos das plantas até causar a ruptura das células e a morte das plantas. Embora promissor, esse método ainda não é amplamente utilizado devido ao alto consumo de energia e limitações na aplicação comercial. A tecnologia ainda se encontra em fase experimental em diversas partes do mundo, incluindo algumas experiências no Brasil.

Esses métodos de controle físico são essenciais em práticas agrícolas que buscam reduzir o uso de químicos, como a agricultura orgânica, e em áreas onde o uso de herbicidas é restrito por legislações ambientais.

3.2.5 Controle Biológico

O controle biológico usa organismos como parasitas, predadores ou patógenos para reduzir a população de plantas daninhas, sem necessariamente erradicá-las. O objetivo é manter a densidade abaixo do nível que causa danos econômicos. Existem três estratégias principais: o controle biológico clássico, que introduz inimigos naturais de plantas daninhas exóticas; a estratégia inundativa, que aplica grandes doses de patógenos para controle rápido; e a estratégia aumentativa, que mantém a pressão de controle com libe-

rações periódicas. Esse método é mais eficaz em áreas extensas e ecossistemas frágeis, mas pode ser limitado em culturas de ciclo curto.

3.2.6 Controle Químico

O controle químico de plantas daninhas teve início no final do século XIX e início do século XX, com a descoberta de substâncias herbicidas que revolucionaram a agricultura. O uso de cultivares transgênicas com resistência a herbicidas, como a soja e o milho tolerantes ao glyphosate, permitiu que esses herbicidas, antes letais para as plantas da cultura, fossem aplicados durante o cultivo, controlando a maioria das espécies de plantas daninhas. A Revolução Verde trouxe um aumento no uso de herbicidas, mas a dependência desse método, sem a rotação de culturas ou outras práticas de manejo, resultou na contaminação ambiental e na seleção de biótipos resistentes. Espécies como a buva e o capim-amargoso tornaram-se problemáticas devido à resistência ao glyphosate.

Vantagens	Desvantagens
Prevenção do aparecimento das plantas daninhas	Toxicidade ao homem e animais
Controle efetivo nas linhas de plantio	Equipamentos próprios para aplicação
Flexibilidade quanto à época de aplicação	Equipamentos de proteção do operador
Redução do tráfego de maquinário na área	Risco de danos por deriva a lavouras vizinhas
Rendimento operacional elevado	Danos a culturas plantadas em sucessão
Menor demanda de mão de obra	Resistência de plantas daninhas a herbicidas

Tabela 3: Vantagens e desvantagens do controle químico de plantas daninhas.

O controle químico é uma ferramenta importante na agricultura moderna, mas deve ser utilizado em conjunto com outros métodos de manejo para garantir sua eficácia e sustentabilidade.

3.3 O Uso de Visão Computacional na Identificação de Ervas Daninhas

Como comentado no tópico de controle mecânico, os avanços em sistemas de detecção contribuiu para o aumento da eficiência de sistemas mecânicos no manejo agrícola, esta seção irá tratar sobre tais sistemas.

No trabalho de Pulido-Rojas, C. A [10] foi proposto um sistema de visão computacional para a detecção de ervas daninhas em plantações de hortaliças. Segundo o autor, na maioria das pequenas e médias propriedades rurais o controle de espécies invasoras é feito utilizando herbicidas e remoção manual. A primeira alternativa levanta preocupações ambientais por não ser seletiva, enquanto a segunda se mostra muito ineficiente a medida que a escala de produção aumenta. A visão computacional pode ser utilizada para desenvolver métodos mais eficientes e sustentáveis de controle de ervas daninhas.




Figura 1: Diagrama de Blocos do Sistema de Visão, Adaptado de [10]

O diagrama de blocos proposto do sistema se mostra é ilustrado na figura abaixo.

A primeira etapa consiste na aquisição de imagens. O ponto chave dessa etapa é minimizar problemas de iluminação e nitidez, reduzindo assim variações de cor na vegetação e mantendo a consistência da cor verde nos objetos.



Figura 2: Imagem de Entrada [10]

Na etapa de subtração de componentes verdes, a imagem é convertida para nível cinza, onde a matiz e saturação são eliminadas, restando a luminância. Posteriormente, todas as componentes no espaço XY correspondente ao valor verde da imagem são subtraídas do elemento correspondente no arranjo de nível cinza. Essa é uma das formas mais práticas de separar as plantas do solo na imagem.




Figura 3: Imagem com componentes subtraídos [10]

Na etapa de filtragem, é utilizado um filtro mediano para a redução de ruído das imagem subtraídas, preservando as bordas e, assim, conservando as informações relevantes da imagem.



Figura 4: Imagem com filtro mediano [10]

A segmentação por limiar é realizada utilizando o método de Otsu, que calcula o limiar ideal por meio de uma busca exaustiva pela máxima variância entre classes de níveis cinza, baseado no histograma da imagem. A imagem abaixo mostra o histograma da foto exemplo. O resultado da segmentação mostra uma separação clara dos objetos na cena.




Figura 5: Histograma [10]




Figura 6: Imagem Segmentada [10]

Na remoção de pequenos objetos o algoritmo começa calculando uma imagem marcada a partir das bordas da imagem original, com o objetivo de identificar os contornos. Em seguida, ele itera até preencher todas as posições da imagem usando uma matriz de 3x3 de uns, resultando em uma imagem binária com os buracos preenchidos. Este método garante que as regiões vazias sejam preenchidas, melhorando a consistência dos objetos para a próxima etapa do processamento. O resultado final desse processo pode ser observado na Figura 7.




Figura 7: Imagem com regiões preenchidas [10]

A última etapa, classificação, inicia-se com a fase de rotulagem. A fase de rotulagem de regiões avalia cada pixel usando conectividade de 4 vizinhos, aplicando uma heurística baseada nos valores de pixel de acordo com os rótulos predecessores nas posições norte e oeste. Esse método permite organizar os pixels em grupos de regiões conectadas, facilitando a extração posterior de características relevantes. Após os objetos da cena serem rotulados, a próxima etapa envolve a extração de características de área de cada elemento para discriminar entre ervas daninhas e a cultura. O algoritmo apresentado define a área contando o número de pixels na região do objeto. Em seguida, esse valor é armazenado para todos os itens identificados.

Os elementos são classificados de acordo com os valores de área em ordem decrescente. Quando a diferença entre a avaliação de um objeto e o próximo é superior a 50%, a média dos elementos anteriores é calculada. Esse valor serve como o limite (threshold) para a

detecção de ervas daninhas. A classificação resultante pode ser observada na Figura 8.



Figura 8: Plantas Detectadas [10]

O algoritmo de detecção foi testado usando fotos capturadas perpendicularmente as linhas de plantio, evitando variações de iluminação em culturas de espinafre e acelga na Universidade Militar de Nueva Granada, Colombia. As imagens foram classificadas manualmente e comparadas posteriormente com a performance do algoritmo. Os parâmetros de comparação para especificidade e sensibilidade foram nomeadas da forma:

- Verdadeiro positivo [VP]: Plantas detectadas como ervas corretamente
- Verdadeiro negativo [VN]: Plantas detectadas como culturas corretamente
- Falso positivo [FP]: Plantas de cultura detectadas como ervas
- Falso Negativo [FN]: Ervas daninhas detectadas como plantas de cultura
- Sensibilidade = $VP/(VP+FN)$
- Especificidade = $VN/(FP+VN)$
- Valor preditivo positivo (PPV) = $VP/(VP+FP)$
- Valor preditivo negativo (NPV) = $VN/(FN+VN)$

Os resultados estão dispostos na tabelas abaixo

	Condição Positiva Verdadeiro Positivo (VP)	Condição Negativa Falso Positivo (FP)	PPV
Detectadas como erva daninha	20	4	0.83
	Falso Negativo (FN)	Verdadeiro Negativo (VN)	NPV
Detectadas como cultivo	2	9	0.818
	Sensibilidade	Especificidade	
	0.909	0.692	

Tabela 4: Sensibilidade e Especificidade na horta de Espinafre 1 [10]

	Condição Positiva Verdadeiro Positivo (VP)	Condição Negativa Falso Positivo (FP)	PPV
Detectadas como erva daninha	80	1	0.98
	Falso Negativo (FN)	Verdadeiro Negativo (VN)	NPV
Detectadas como cultivo	5	6	0.545
	Sensibilidade	Especificidade	
	0.94	0.857	

Tabela 5: Sensibilidade e Especificidade na horta de Espinafre 2 [10]

	Condição Positiva Verdadeiro Positivo (VP)	Condição Negativa Falso Positivo (FP)	PPV
Detectadas como erva daninha	146	1	0.99
	Falso Negativo (FN)	Verdadeiro Negativo (VN)	NPV
Detectadas como cultivo	12	13	0.52
	Sensibilidade	Especificidade	
	0.924	0.92	

Tabela 6: Sensibilidade e Especificidade na horta de acelga [10]

Os valores de sensibilidade mostrados nessa seção são do entorno de 0.90 , o que indica uma boa performance do algoritmo em detectar ervas daninhas corretamente. De forma similar os valores de especificidade próximos de 1 mostram a habilidade do sistema em detectar plantas como cultura. Os valores preditivos positivos foram maiores do que 80 por cento, onde a maioria dos casos foi classificada como ervas daninhas eram verdadeiros positivos. Em contrapartida, os valores negativos previstos eram próximos de 0.7, o que significa 30 por cento de falsos negativos obtidos quando o tamanho das ervas daninhas eh maior ou próximo ao valor das plantas cultivadas.

Outros métodos de detecção são similares como o desenvolvido por Malemath (V.S Malemath 2016)[8], que utiliza a frequência de pixels em uma região da tela para determinar o tipo de planta ao invés de comparação de área, todavia tem a desvantagem de separar a imagem em quadrantes fixos para a análise. Também existem algoritmos de segmentação mais complexos e sofisticados na literatura, entretanto não são rápidos o suficiente para aplicações em tempo real.

3.4 Técnicas de Inteligência Artificial aplicadas à detecção de ervas Daninhas

As Redes Neurais Convolucionais (CNNs) têm se mostrado altamente eficazes em tarefas de classificação de imagens e detecção de padrões, especialmente em aplicações agrícolas, como a identificação de ervas daninhas. Segundo um levantamento realizado por pesquisadores da Michigan State University [4]. Existem diversas bases de dados com imagens de diversas especies de ervas daninhas e cultivares. Porém, poucos destes

conjuntos foram fotografados usando veículos autônomos, um ponto a se considerar, uma vez fatores como o ângulo da câmera e iluminação do ambiente no conjunto de imagens de treinamento devem possuir semelhança suficiente com as condições do ambiente de aplicação da rede neural. Outro ponto a se considerar são as espécies de plantas presentes nos datasets. Em sua maior parte, as capturas de imagens foram conduzidas em países de clima temperado, dado que os principais esforços dessa área se concentram nos Estados Unidos, China e Europa. Dessa forma, é um desafio adaptar os dados disponíveis para a realidade da agricultura tropical brasileira.

Após a seleção de um conjunto adequado de imagens para treinar a rede neural, é essencial determinar qual modelo de Rede Neural Convolucional (CNN) será utilizado no sistema.

Nesta etapa, será realizado uma análise detalhada dos modelos de CNN mais otimizados para sistemas embarcados, devido às suas restrições de processamento e memória. A revisão dos modelos utilizados em pesquisas anteriores, voltados à detecção de plantas invasoras, permitirá identificar as arquiteturas que apresentam melhor desempenho e que podem ser ajustadas às especificidades do projeto.

As duas tabelas abaixo, retiradas do artigo "Deep learning based weed detection and target spraying robot system at seedling stage of cotton field"[5] mostram a comparação dentre os modelos de redes neurais mais otimizados para o uso em sistemas embarcados, sendo que **mAP** corresponde a precisão média do modelo.

Tabela 7: Comparação entre modelos de detecção de objetos[5]

Model	mAP (%)	Tempo de Inferência (ms)
SSD	87.23	297
YOLO v3	89.17	93
YOLO v5s	91.11	39
YOLO v5l	94.82	62
YOLO v5x	95.73	78
Faster R-CNN	94.69	261
Faster R-CNN Melhorado	98.43	165

Com os dados apresentados, é possível perceber que a arquitetura YOLOv5 conseguem manter o melhor equilíbrio entre precisão e tempo de detecção, duas características importantes para a aplicação no controle de ervas daninhas. Ademais, os modelos YOLO possuem ampla difusão na comunidade de visão computacional, sendo que existem muitos materiais informativos disponível a respeito dessa arquitetura.

Outro aspecto interessante é a variação da precisão dos modelos dependendo das condições de iluminação, conforme a tabela abaixo, retirada do mesmo artigo.

A precisão cai consideravelmente durante dias de chuva e drasticamente durante a noite, com 5 pontos percentuais de diferença. Dessa forma, se faz necessário perceber que a tecnologia ainda possui limitações. Entretanto, ainda assim se faz mais precisa do

Tabela 8: Detecção de ervas daninhas sob diferentes condições de luz e clima [5]

Condições de Aquisição de Imagem	Número de Imagens	mAP (%) - Faster R-CNN
Dia ensolarado	224	94.73
Dia nublado	198	94.68
Dia chuvoso	177	92.16
Anoitecer	181	89.74

que métodos tradicionais de processamento de imagem. Ademais, o efeito da variabilidade luminosa poderia ser mitigado utilizando-se iluminação artificial e/ou um espectro luminoso diferente.

3.5 Projetos Anteriores

A análise da literatura revela que robôs vem sido testados para o combate de ervas daninhas há mais de 25 anos, contudo apenas na última década as plataformas começaram a ter boa precisão, devido ao desenvolvimento de redes neurais mais leves e embarcáveis, conforme a tabela a seguir. Adaptada do artigo "Key technologies of machine vision for weeding robots: A review and benchmark"[7].

Tabela 9: Avaliação de Sistemas de Controle de Ervas Daninhas [7]

Nome	Método de Remoção	Aplicação/Performance	Referencias
Lee's Robot	Químico	Precisão = 73.1% (Tomate), 68.8% (Erva), Velocidade = 1.2 km/h	(Lee et al., 1999)
Astrand's Robot	Mecânico	Precisão = 77% (Beterraba), 87% (Erva), Precisão de Orientação = ± 2 cm	(Astrand and Baerveldt, 2002)
Bakker's Robot	Não Especificado	Sistema autônomo baseado em visão de maquina e RTK-DGPS	(Bakker, 2009)
BoniRob	Mecânico	Taxa de controle = 93.86%	(Sellmann et al., 2014; Langsenkamp et al., 2014; Lottes et al., 2017)
AgBotII	Químico ou Mecânico	Precisão = 92.3% (Erva), Controle Mecânico/Químico baseado em especies	(Bawden et al., 2017; Hall et al., 2017)
Digo	Químico	Reduz uso de Herbicidas em 90% com o sistema Drop-On-Demand	(Utstumo et al., 2018)
Deepfield	Mecânico	Classificação Online e controle mecânico	(Amend et al., 2019)
Naiture	Mecânico	Testado em campo para controle de pragas (2019)	(Naiture, 2019)
AVO	Químico	Trata ate 10ha/dia, usando até 95% menos herbicida	(EcoRobotix, 2020)
FarmWise	Mecânico	Provê serviços de controle para produtores	(FarmWise, 2020)
Carbon's LaserWeeder	Óptico	Elimina mais de 100,000 ervas por hora	(Carbon Robotics, 2021)

Considerando agora os métodos de controle, grande parte dos sistemas foi desenvolvida com o intuito de fazer o uso de herbicidas de forma mais precisa, já sendo utilizada de forma comercial. A fabricante John Deere. já utiliza essa expertise em seus produtos, sob a marca SEE & SPRAYTM. Todavia, essa abordagem não elimina completamente os problemas citados na seção de introdução deste documento.

O uso de lasers de alta potencia como forma de controle tem como ponto positivo a alta velocidade, entretanto essa radiação luminosa pode causar danos ao solo e para operadores que estejam sem os EPIs necessários.

Em suma, a remoção de ervas daninhas utilizando métodos mecânicos é seguramente a maneira mais lenta das aqui avaliadas. No entanto, é exatamente o que humanos vem fazendo há milhares de anos na agricultura. Pela sua simplicidade e atendimento dos requisitos estipulados, essa é atualmente a melhor forma de combate contra ervas daninhas.

Por fim, a revisão bibliográfica nos mostra que a esmagadora maioria dos projetos são desenvolvidos fora do Brasil, apontando a necessidade de iniciativas que visem a redução ou fim do uso de herbicidas para o controle de ervas daninhas no contexto da agricultura brasileira.




Figura 9: Divisão das Etapas do Projeto

4 Metodologia e Cronograma

Este projeto será desenvolvido em sete etapas principais, descritas a seguir, com o objetivo de criar um sistema eficiente para identificação e controle de ervas daninhas em culturas agrícolas. Cada etapa é detalhada para garantir clareza nos objetivos e atividades correspondentes.

Etapa 1: Revisão Bibliográfica

Esta etapa inicial visa construir uma base teórica sólida para o desenvolvimento do projeto. As atividades incluem:

Estudo sobre bancos de imagens relevantes para o treinamento de redes neurais e técnicas de processamento de imagens. Pesquisa de modelos de redes neurais convolucionais otimizados para sistemas embarcados, com foco em detecção de ervas daninhas. Análise de projetos anteriores para identificar boas práticas e soluções existentes, avaliando pontos fortes e limitações.

Etapa 2: Obtenção e Organização dos Bancos de Imagens

Nesta etapa, serão obtidos bancos de imagens apropriados para o treinamento do algoritmo. As imagens serão organizadas, catalogadas e pré-processadas para atender aos requisitos do sistema.

Etapa 3: Treinamento do Algoritmo para Diferenciação e Cálculo de Posições

Objetivo: Desenvolver e treinar um modelo de rede neural capaz de diferenciar ervas daninhas das culturas agrícolas, além de calcular suas posições na imagem.

Atividades:

1. Preparação dos Dados:

- Dividir os bancos de imagens em conjuntos de treinamento, validação e teste.

2. Configuração do Ambiente de Treinamento:

- Escolher a arquitetura de rede neural mais adequada, como MobileNet ou YOLO.

3. Treinamento do Modelo:

- Utilizar frameworks para treinar a rede neural.
- Monitorar métricas de desempenho durante o treinamento.

4. Validação e Ajustes:

- Avaliar o modelo no conjunto de validação para identificar overfitting ou underfitting.
- Realizar fine-tuning para otimização.

5. Teste Final:

- Avaliar o modelo no conjunto de teste e calcular métricas finais de desempenho.

Resultados Esperados: Um modelo robusto capaz de identificar e localizar ervas daninhas com alta precisão.

Etapa 4: Desenvolvimento do Sistema Embarcado

Objetivo: Implementar o algoritmo treinado em um sistema embarcado para processamento em tempo real.

Atividades:

1. Seleção de Hardware:

- Escolher uma plataforma embarcada apropriada, como Raspberry Pi, Jetson Nano ou um microcontrolador com capacidade de processamento.

2. Integração do Algoritmo:

- Implementar o código do algoritmo adaptado ao hardware.
- Desenvolver a interface de comunicação entre o sistema embarcado e os sensores ou atuadores (ex.: câmeras, motores).

3. Testes Unitários:

- Verificar a funcionalidade de cada componente (ex.: processamento de imagem, controle de hardware).

Resultados Esperados: Um sistema embarcado funcional capaz de executar o algoritmo em tempo real.

Etapa 5: Integração do Sistema à Plataforma de Testes

Objetivo: Acoplar o sistema embarcado a um robô de testes e preparar o conjunto para validações em ambiente controlado e em campo.

Atividades:

1. Montagem Física:

- Integrar o hardware embarcado ao robô, garantindo que a câmera e os atuadores estejam posicionados corretamente.
- Ajustar os componentes mecânicos, como braços robóticos ou rodas, conforme necessário.

2. Testes de Integração:

- Testar a comunicação entre o sistema embarcado e o robô.
- Avaliar a sincronização entre o algoritmo de detecção e os comandos de movimentação/remoção de ervas daninhas.

3. Ajustes Finais:

- Resolver problemas identificados nos testes iniciais de integração.
- Implementar melhorias para garantir o funcionamento contínuo e estável.

4. Simulação de Cenários:

- Realizar testes em ambiente controlado, simulando condições reais de campo.

Resultados Esperados: Um sistema integrado e operacional, pronto para validação em campo.

Etapa 6: Testes e Análise de Dados para Avaliação do Sistema

Serão realizados testes em campo para avaliar o desempenho do sistema em condições reais. As atividades incluem:

Coleta de dados sobre a eficácia na identificação e controle de ervas daninhas. Análise dos resultados para identificar pontos de melhoria.

Etapa 7: Relatório Final

Na etapa final, será elaborado um relatório técnico contendo:

Descrição detalhada das etapas realizadas. Resultados obtidos nos testes. Conclusões e sugestões para trabalhos futuros.

4.1 Cronograma

O Cronograma, com as etapas contempladas, é mostrado na figura a seguir.

	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6	Mês 7	Mês 8	Mês 9
Etapa 1									
Etapa 2									
Etapa 3									
Etapa 4									
Etapa 5									
Etapa 6									
Etapa 7									

Figura 10: Cronograma

5 Materiais e Infraestrutura

Em relação aos materiais e à infraestrutura utilizada para a realização desta pesquisa, além de um computador, serão necessários:

- **Câmeras:** Necessárias para a captura das imagens da lavoura, que serão processadas pelo algoritmo.
- **Placas de Computação Embarcada:** As placas de computação embarcada, como Raspberry Pi ou Toradex são necessárias para executar os algoritmos baseados em redes neurais que irão processar e determinar os alvos para a remoção em tempo real.
- **Serviços de Computação em Nuvem e Armazenamento:** Compõem parte essencial para o treinamento e ajustes das redes neurais convolucionais.
- **Motores Servo:** Importantes para o controle do dispositivo de remoção mecânico de plantas.
- **Espaços para teste:** É preciso um espaço de testes, em uma propriedade rural para a coleta de dados e validação do projeto.

6 Resultados

Considerando que esta proposta envolve estudos em nível de iniciação científica, espera-se que o aluno desenvolva suas habilidades de pesquisa e competências tecnológicas. Portanto, o aprimoramento da formação científica do aluno é o resultado mais importante almejado neste projeto. Espera-se que o aluno se qualifique tecnicamente através da execução do plano proposto, tanto na ampliação de seu conhecimento metodológico quanto nas experiências computacionais esperadas. Além disso, espera-se que os resultados deste projeto contribuam cientificamente para a área de automação agrícola e robótica autônoma.

Referências

- [1] Fernando Storniolo Adegas et al. “Impacto Econômico da Resistência de Plantas Daninhas a Herbicidas no Brasil”. Em: *Circular Técnica* (2017). URL: <https://ainfo.cnptia.embrapa.br/digital/bitstream/item/162704/1/CT132-0L.pdf>.
- [2] GSAC Barros et. al. “PIB do Agronegócio Sofre Queda no Primeiro Trimestre Devido aos Baixos Preços Agropecuários”. Em: *CEPEA Esalq/USP* (2024). URL: https://www.cepea.esalq.usp.br/upload/kceditor/files/Cepea_CNA_1tri_2024_PIBAgroBrasil.pdf.
- [3] Björn Åstrand e Albert-Jan Baerveldt. “An Agricultural Mobile Robot with Vision-Based Perception for Mechanical Weed Control”. Em: *Autonomous Robots* 13.1 (2002), pp. 21–35. DOI: 10.1023/A:1015674004201. URL: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-0036645195&doi=10.1023%2fA%3a1015674004201&partnerID=40&md5=0a45b64c312761c256b10709fa9daf31>.
- [4] Boyang Deng, Yuzhen Lu e Jiajun Xu. “Weed Database Development: An Updated Survey of Public Weed Datasets and Cross-Season Weed Detection Adaptation”. Em: *Ecological Informatics* 81 (2024), p. 102546. ISSN: 1574-9541. DOI: 10.1016/j.ecoinf.2024.102546. URL: <https://www.sciencedirect.com/science/article/pii/S1574954124000888>.
- [5] Xiangpeng Fan et al. “Deep Learning-Based Weed Detection and Target Spraying Robot System at Seedling Stage of Cotton Field”. Em: *Computers and Electronics in Agriculture* 214 (2023), p. 108317. ISSN: 0168-1699. DOI: 10.1016/j.compag.2023.108317. URL: <https://www.sciencedirect.com/science/article/pii/S0168169923007056>.
- [6] W. S. Lee, D. C. Slaughter e D. K. Giles. “Robotic Weed Control System for Tomatoes”. Em: *Precision Agriculture* 1.1 (1999), pp. 95–113. DOI: 10.1023/A:1009977903204. URL: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-0001797621&doi=10.1023%2fA%3a1009977903204&partnerID=40&md5=c393943548781bd0fba87f85e2de3695>.
- [7] Yong Li et al. “Key Technologies of Machine Vision for Weeding Robots: A Review and Benchmark”. Em: *Computers and Electronics in Agriculture* 196 (2022), p. 106880. ISSN: 0168-1699. DOI: 10.1016/j.compag.2022.106880. URL: <https://www.sciencedirect.com/science/article/pii/S0168169922001971>.
- [8] V. S. Malemath e Sharanamma M. Hugar. “A new approach for weed detection in agriculture using image processing techniques.” Em: *International Journal of Advanced Scientific and Technical Research* (2016). URL: <https://rspublication.com/ijst/2016/june16/29.pdf>.

- [9] M. F. de OLIVEIRA e A. M. BRIGHENTI. *Controle de plantas daninhas: métodos físico, mecânico, cultural, biológico e alelopatia*. Embrapa Milho e Sorgo, 2018. URL: <https://www.embrapa.br/busca-de-publicacoes/-/publicacao/1103281/control-de-plantas-daninhas-metodos-fisico-mecanico-cultural-biologico-e-alelopatia>.
- [10] C. A. Pulido-Rojas, M. A. Molina-Villa e L. E. Solaque-Guzmán. “Machine vision system for weed detection using image filtering in vegetables crops”. Em: *Revista Facultad de Ingenieria, Universidad de Antioquia* (2016). URL: https://www.researchgate.net/publication/309276796_Machine_vision_system_for_weed_detection_using_image_filtering_in_vegetables_crops.
- [11] A. F. da et. al. Silva. “Monitoramento de Plantas Daninhas Resistentes a Glifosato no Brasil”. Em: *Embrapa Milho e Sorgo. Boletim de Pesquisa e Desenvolvimento, 234* (2021). URL: <https://ainfo.cnptia.embrapa.br/digital/bitstream/item/229311/1/BOL-234-Monitoramento-plantas-resistentes-glifosato.pdf>.
- [12] Alexandre Ferreira da Silva, Adriene Caldeira Batista e Ricardo Siqueira da Silva. “Dispersão de Plantas Daninhas Resistentes a Glifosato no Brasil: Recomendações de Manejo”. Em: *Embrapa* (2023). URL: <https://ainfo.cnptia.embrapa.br/digital/bitstream/doc/1158894/1/Dispersao-de-plantas-daninhas-resistentes-a-glifosato-no-Brasil.pdf>.